

虚拟细胞算法赛题解读

周梓卓

西湖大学郭天南实验室


Guomics Laboratory for Proteome Complexity Science, Westlake University
Westlake Center for Intelligent Proteomics, Westlake Laboratory

guomics.com


Outline

- 1, 赛题背景与科学价值
- 2, 任务定义
- 3, 数据结构
- 4, 评测逻辑
- 5, 基线模型
- 6, 建模方向

What is AI virtual cell?



Karr et al., *Cell* (2012)



Thornburg et al., *Cell* (2026)

传统的虚拟细胞（全细胞模型）：模拟细胞生物学功能及其相互作用的计算模型

Cell
Leading Edge

Perspective

How to build the virtual cell with artificial intelligence: Priorities and opportunities

Charlotte Bunne,^{1,2,3,4,50} Yusuf Roohani,^{1,3,5,50} Yanay Rosen,^{1,3,50} Ankit Gupta,^{3,6} Xikun Zhang,^{1,3,7} Marcel Roed,^{1,3} Theo Alexandrov,^{8,9} Mohammed AlQuraishi,⁹ Patricia Brennan,³ Daniel B. Burkhardt,¹¹ Andrea Califano,^{10,12,13}

(Author list continued on next page)


Bunne et al., *Cell* (2024)

50CellPress
OPEN ACCESS

AI virtual cell : A **learned simulator** of cells and cellular systems **under varying conditions and changing contexts**.


AIVC = data learned representation + cell-state simulator + virtual experiment system

How to build the AI virtual cells?




Roohani et al., *Cell* (2025)

第一届虚拟细胞挑战赛：AI 能否跨细胞背景预测遗传扰动后的转录响应？



Qian, L., Dong, Z., & Guo, T. *Cell Res.* 2025

Towards the construction of a virtual yeast



Conceptual roadmap of the virtual yeast AI agent

Qian et al., *Nature* (2026)

为什么要做一个酵母的虚拟细胞？

1. 生物学上足够复杂：它是完整的真核细胞
2. 实验上足够可控：可以系统探索扰动空间
3. 模型上足够可验证：预测可以快速回到实验

科学问题：

AI 能否跨细胞背景预测遗传扰动和化合物扰动后的蛋白质组响应？

建模任务：

每个样本由菌株、化合物、培养基、温度、处理时间以及测量上下文共同描述。模型的目标是输出该样本对应的完整蛋白质组强度向量。

菌株 + 化合物 + 实验条件 → 蛋白质组响应

Data structure

数据文件	数据文件名称	样本数	主要内容	开放情况
训练及验证元数据	WAYB WAYC metadata train val.csv	8,958	15 个条件与测量字段	开放
训练及验证蛋白质组	WAYB WAYC proteome raw train val.csv	8,958	5,243 个蛋白的 raw intensity	开放
测试元数据	WAYB WAYC metadata test.csv	4,454	15 个条件与测量字段	开放
测试蛋白质组真值	WAYB WAYC proteome raw test.csv	4,454	仅用于主办方内部评测	不开放

pert_id = 48
Quality Control
同一起来源的样本用于评估批次效应

Data : 6 strains * 56 chemicals * 2 media * 2 temperature * 6 time points

6 strains : 4 for training, 1 for validation, 1 for test

55 chemicals : 38 for training, 6 for validation, 11 for test

我们从每个条件对应的6个时间点中随机留出一些用于比较时间插值预测能力

Dataset split	training strains	validation strains	test strains
training chemicals	Train	Val_strain_only	Test_strain_only
validation chemicals	Val_chem_only	Val_both	Test_both
test chemicals	Test_chem_only	Test_both	Test_both

正交划分

- Seen strain, seen chemical
- Unseen strain, seen chemical
- Seen strain, unseen chemical
- Unseen strain, unseen chemical

Data preprocessing

1. 预处理：蛋白质组中的 NA 主要来自检测限、肽段覆盖和实验条件差异。NA 不是数值 0，也不应在读入数据后统一填成 0。一个稳妥的处理流程如下：

- **样本对齐**：以 sample_ID 为唯一键对齐元数据和蛋白矩阵，不能依赖两张表当前的行顺序。
- **蛋白过滤**：仅使用训练行计算缺失率，删除在 80% 及以上训练样本中缺失的蛋白。
- **缺失掩码**：其余蛋白保留观测 mask，训练损失和验证指标只在真值存在的位置计算。
- **尺度转换**：对非缺失的 raw intensity 做 log2；模型内部如需标准化，均值和标准差也只能从训练集估计。

按当前冻结划分，split_final=train 共 5,920 个样本。以这些样本计算缺失率后，5,243 个蛋白中保留 4,232 个，删除 1,011 个。

2. 数据输出尺度：参赛者提交 log2 intensity。主办方评测时会将所有结果统一到 log2 尺度后比较。z-score 等标准化只适合模型内部训练，不能直接作为 prediction.csv 提交；如果模型在标准化空间训练，输出前必须还原到 log2 的生物尺度。

提交尺度	是否允许	评测端处理
raw intensity	不允许	需转换到 log2
log2 intensity	允许	直接进入统一评测尺度
z-score / 标准化空间	不允许	无法与其他模型在统一生物尺度上比较

Evaluation

评分模块	权重	计算方式、适用划分与取向
绝对保真度 (全蛋白质组真实性)	20%	适用全部划分。逐样本 corr / R^2 (每个样本的预测向量对真值向量) 与逐蛋白 corr / R^2 (每个蛋白跨样本) : PCC 刻画蛋白谱形状, R^2 刻画幅度与校准 (可为负) 。样本轴与蛋白轴分别聚合, 避免高丰度易预测蛋白掩盖困难样本。
匹配对照原始 FC (扰动效应预测)	25%	所有 OOD 划分的核心指标。 $\Delta_{\text{pred}} = \hat{y}_{\text{treat}} - y_{\text{control}}$, $\Delta_{\text{true}} = y_{\text{treat}} - y_{\text{control}}$, 计算 $\text{PCC}(\Delta_{\text{pred}}, \Delta_{\text{true}})$ 。对照须匹配来源、菌株、培养基、温度、时间、仪器、板号, 并按官方规则匹配到 DMSO 或 Water。评估模型能否捕捉药物/扰动引起的真实蛋白质组变化。
上下文均值残差 (新化合物的特异响应)	20%	适用 test_chem_only 等新化合物划分。 $\mu_{\text{ctx}} =$ 同上下文下训练药物的 Δ_{true} 均值; 计算 $\text{PCC}(\Delta_{\text{pred}} - \mu_{\text{ctx}}, \Delta_{\text{true}} - \mu_{\text{ctx}})$ 。剔除同一菌株/培养基/温度/时间/冻结批次下的共享药物响应分量, 聚焦留出化合物的特异作用机制方向。
药物均值残差 (新菌株/上下文的背景调制)	20%	适用 test_strain_only 等新菌株划分。 $\mu_{\text{drug}} =$ 同药物下训练上下文的 Δ_{true} 均值; 计算 $\text{PCC}(\Delta_{\text{pred}} - \mu_{\text{drug}}, \Delta_{\text{true}} - \mu_{\text{drug}})$ 。剔除同一药物共享的平均作用机制谱, 评估模型能否预测未见菌株/上下文如何调制该响应。
双重未知 / 时间外推	10%	适用 test_both 与 test_time。test_both 以原始 FC + 绝对保真度为主; test_time 以绝对保真度 + 原始 FC 为主。组合外推缺乏稳定的训练实体均值, 不强制以残差为唯一主指标, 重点在完整蛋白质组与扰动方向是否可靠。
高效应蛋白与 DEP 检出	5%	全部划分的补充指标。对 $ \Delta_{\text{true}} > 1$ 的蛋白, 计算方向准确率、高效应 PCC、Recall@K、F1 或 AUPRC。Recall 不单用, 须与 precision、F1 或 AUPRC 组合, 避免「全报阳性」刷高召回。
复现与合规	晋级门槛	全部提交。审查代码、随机种子、归一化流程、外部数据使用与测试泄漏风险, 可作为奖项与晋级门槛。

隐藏机理评估：隐藏机理评估可用于赛后分析或特别展示 (如从预测蛋白质组推断药物作用机制, 或对照公开遗传扰动与药物响应数据评估机理一致性) , 不作主榜排名依据。

Baseline

- **蛋白均值基线**: 对每个保留蛋白计算训练集非缺失 log2 均值, 并对所有样本输出同一向量。
- **Control 基线**: 对每个处理样本查找同一数据来源、仪器、实验板、菌株、培养基、温度和处理时间下的 Water/DMSO 对照, 并以这些 matched control 的 log2 蛋白质组均值作为预测。

```
train = metadata['split_final'].eq('train')
missing_rate = proteome.loc[train].isna().mean(axis=0)
keep = missing_rate < 0.80
y_log2 = np.log2(proteome.loc[:, keep])
protein_mean = y_log2.loc[train].mean(axis=0)
prediction = np.tile(protein_mean.values, (len(test_metadata), 1))
```

per condition R^2 vs per protein R^2



场景	基线	样本数	log2 RMSE	Global R^2	蛋白 R^2 中位数
双重未知	蛋白均值	266	0.994	0.871	-0.064
双重未知	Matched control	266	0.382	0.980	0.809
新化合物	蛋白均值	1,015	1.004	0.868	-0.038
新化合物	Matched control	1,015	0.379	0.980	0.836
新菌株	蛋白均值	1,293	0.875	0.897	-0.036
新菌株	Matched control	1,293	0.399	0.978	0.726
时间验证	蛋白均值	128	0.869	0.900	-0.009
时间验证	Matched control	128	0.426	0.975	0.719

数据相似性高, 重点关注同 protein 在不同 condition 的变化下是否能够预测准

One possible modeling approach



Strain genome 获取参考 <http://1002genomes.u-strasbg.fr/files/>



Peter et al. (2018), Genome evolution across 1,011 *Saccharomyces cerevisiae* isolates, *Nature* 556:339–344.
 DHY210是S288c background,其genome可以参考S288c 标准基因组: *Saccharomyces* Genome Database

Thanks!

周梓卓

西湖大学郭天南实验室

Guomics Laboratory for Proteome Complexity Science, Westlake University

Westlake Center for Intelligent Proteomics, Westlake Laboratory

guomics.com